Thai Overt-Mimed Speech EEG

Nontapat Auetrongjit (Firm)

Introduce

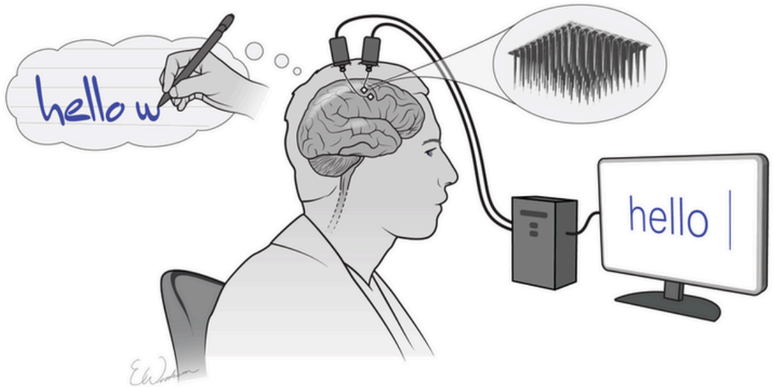


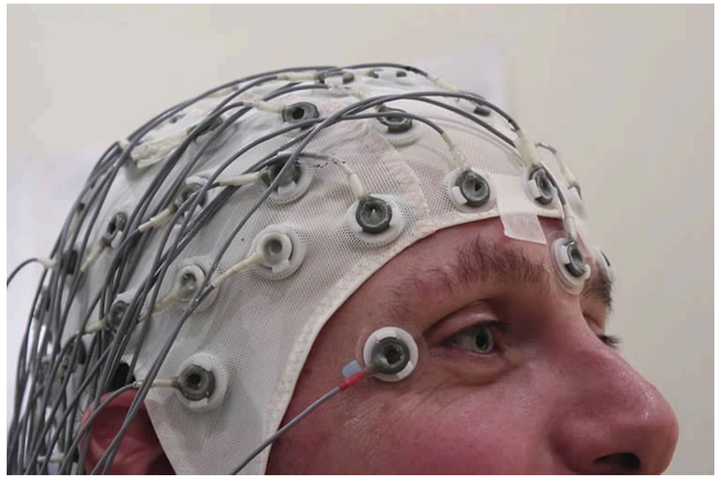
Nontapat Auetrongjit (Firm)

2nd-year B.Eng. student in Computer Engineering and Digital Technology (CEDT), Chulalongkorn University

Project Background

- การสื่อสารด้วยเสียงอาจทำไม่ได้สำหรับผู้ที่มีข้อจำกัดด้านการพูด
- *EEG* เป็นแนวทางหนึ่งในการศึกษาว่า ความตั้งใจจะพูดคำใด สะท้อนอยู่ในสัญญาณที่บันทึกจากศีรษะหรือไม่
- โครงการนี้จึงเริ่มจากความต้องการพัฒนาพื้นฐานของ ระบบสื่อสารคำภาษาไทยโดยวิเคราะห์คลื่นสัญญาณสมอง



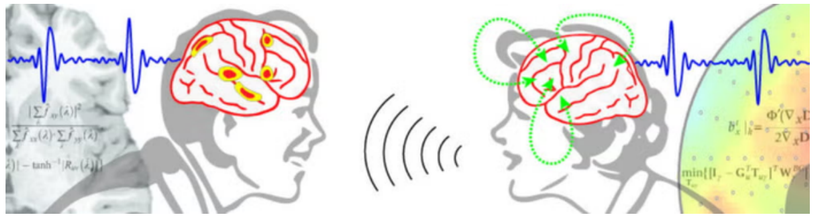


Objective / Goal

ประเมินว่าสัญญาณ *EEG* ระหว่างการพูดแบบ *Overt* และ *Mimed* ใช้จำแนกคำภาษาไทยได้เพียงใด ทั้งในคนเดิมและคนใหม่ พร้อมระบุข้อจำกัดของผลที่อาจเกิดจากเงื่อนไขการบันทึกและสัญญาณรบกวน

คำถามวิจัย

- จำแนกคำได้ดีและเสถียรแค่ไหน? เปรียบเทียบ *Within-subject*, *Cross-subject* แบบ *LOSO* และกรณีที่มีตัวอย่างจากคนใหม่
- ความถี่และการเตรียมสัญญาณส่งผลอย่างไร? เปรียบเทียบย่านความถี่และ *ICA* โดยตรวจว่าคะแนนที่เปลี่ยนไปตีความได้แค่ไหน
- *Overt* กับ *Mimed* ใช้แทนกันได้ไหม? เปรียบเทียบผลของสองโหมดและทดสอบการฝึกโหมดหนึ่งไปใช้กับอีกโหมด

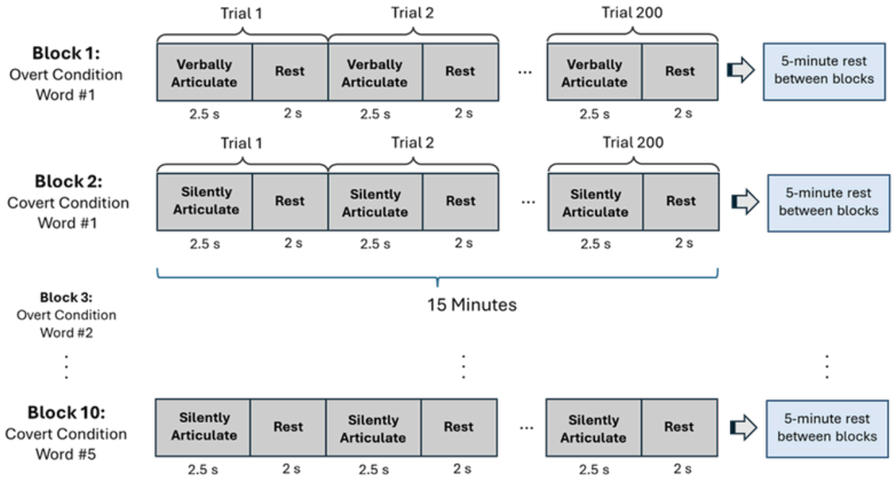


Dataset

Thai Overt-Mimed Speech EEG Dataset

This dataset contains electroencephalography (EEG) recordings from 20 participants performing a Thai word-production task. The vocabulary consisted of 20 Thai words divided into two sets of 10 words. Set 1 included: 1) turn on the light, 2…

Mendeley Data / May 29



Dataset มีผู้เข้าร่วม 20 คน แบ่งเป็นสองชุด ชุดละ 10 คน และแต่ละชุดใช้คำ 10 คำต่างกัน มีการพูดออกเสียง (**Overt**) และขยับปาก/ลิ้นโดยไม่ออกเสียง (**Mimed**). ข้อมูลที่ใช้วิเคราะห์มี 32 ช่อง, 512 Hz, epoch ยาว 2 วินาที และ **200 trials ต่อคำ/โหมด/คน**

ชุดที่ 1 คนกลุ่ม 1 (10 คน)

Day 1	1. เปิดไฟ	2. ปิดไฟ	3. อุจจาระ	4. ปัสสาวะ	5. หิวข้าว
Day 2	6. หิวน้ำ	7. เศร้า	8. กลัว	9. โกรธ	10. ดีใจ

ชุดที่ 2 คนกลุ่ม 2 (10 คน)

Day 1	1. เช็ดตัว	2. ใช่	3. ไม่	4. หมอ	5. ปวด
Day 2	6. หัว	7. ขา	8. แขน	9. หลัง	10. คอ

Preprocessing

01 | Scale Restoration

eeg × scale คืนค่าแรงดันไฟฟ้าจริง (V / μV)

02 | Spatial Re-referencing

ขจัด Common-mode noise ด้วย CAR หรือ Channel Demeaning

03 | Frequency Selection

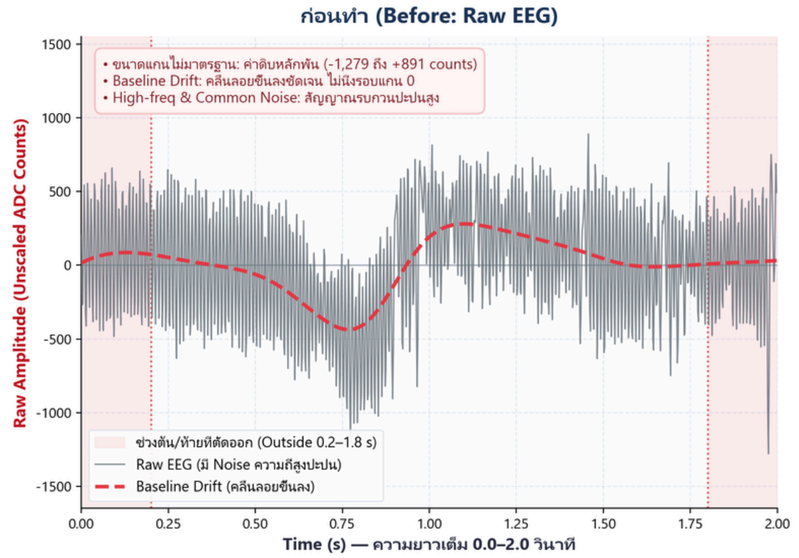
กรองย่านความถี่ด้วย Time-domain Bandpass filter

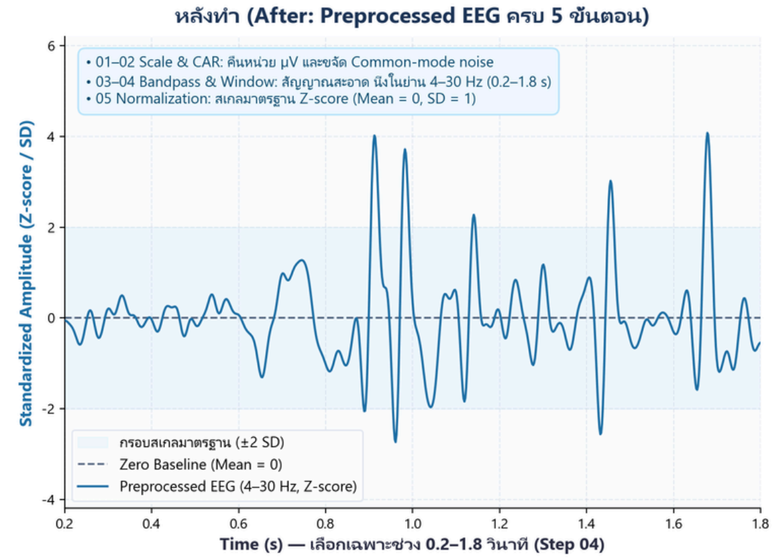
04 | Time Windowing

เลือกช่วง 0.2–1.8 วินาทีเพื่อลดผลของช่วงต้น trial

05 | Signal Normalization

ปรับสเกลมาตรฐานด้วย z-score หรือ StandardScaler





Within-Subject

Pipeline

01 | Input & Data

5. ปวด	6. หัว
7. ขา	8. แขน

4 Target Classes
chance 25%

เรียงตามลำดับ trial ในแต่ละ Word Block

02 | Model & Training

🟩 64% Train
🟨 16% Validation
🟦 20% Test

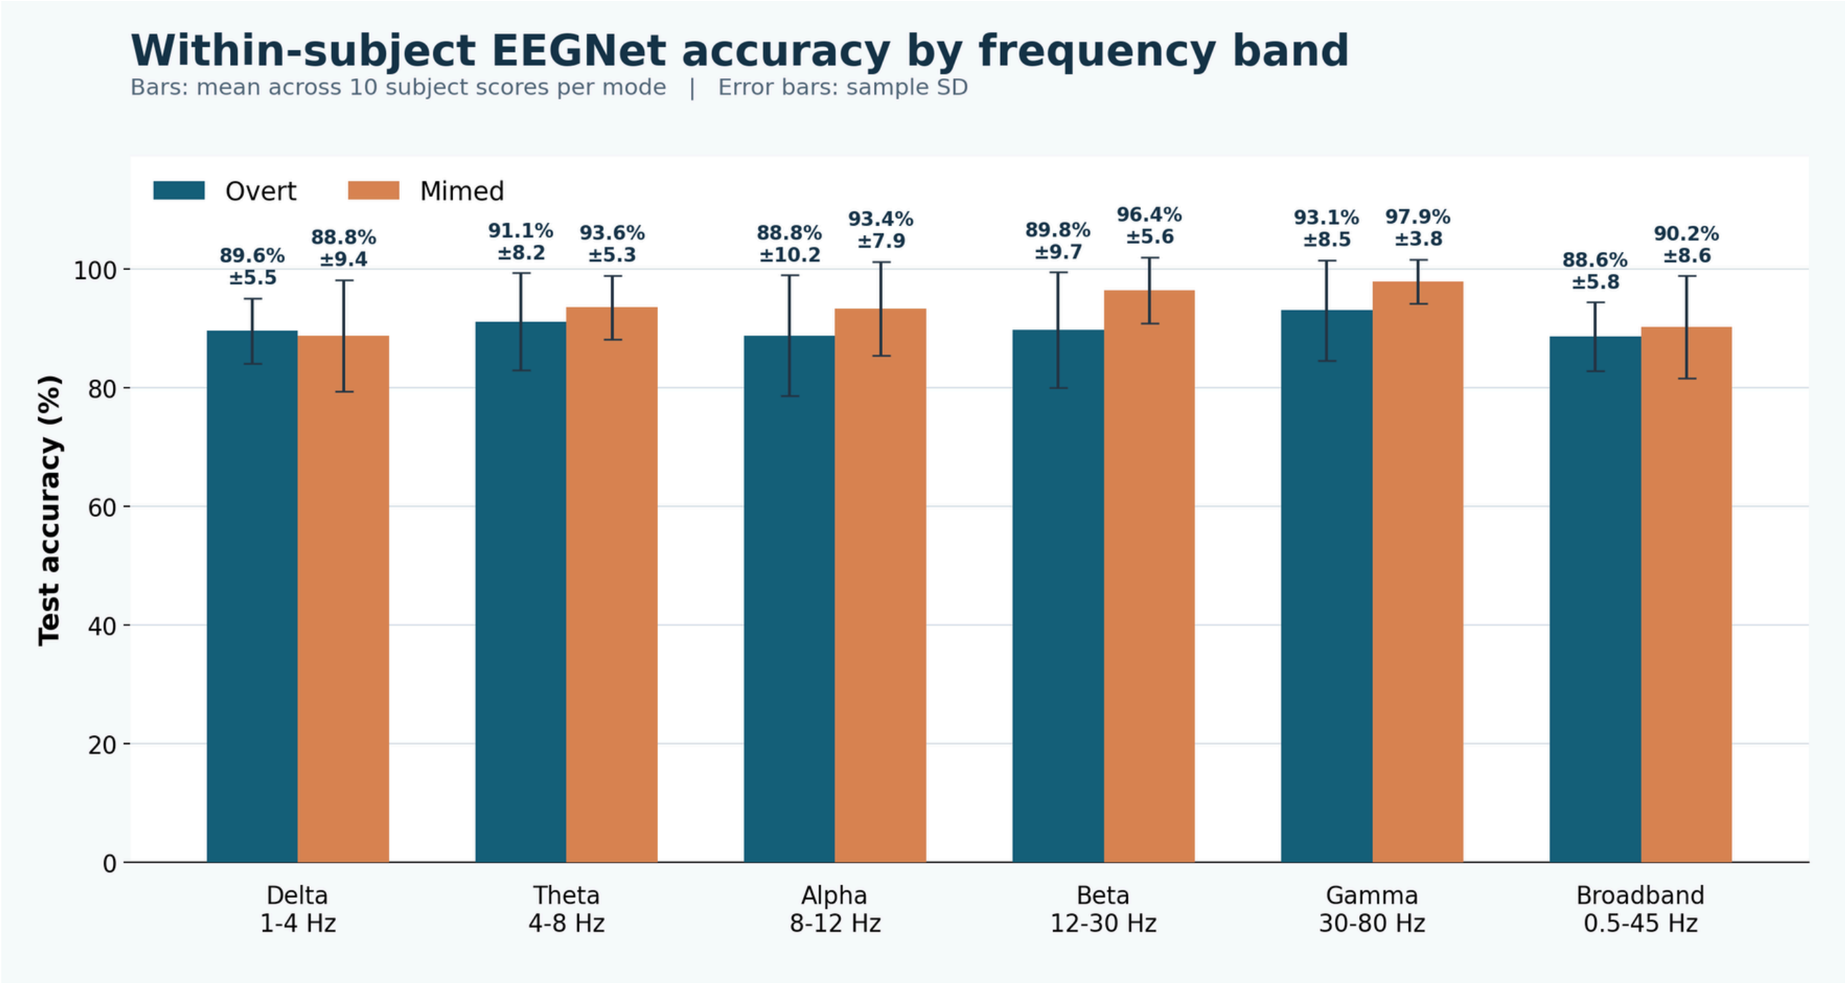
EEGNet Training 100 Epochs

03 | Evaluation

Within-Subject Evaluation

Evaluate ผลลัพธ์แยกทีละบุคคล รวมทั้งหมด 10 คน และนำมาเฉลี่ย

Frequency Analysis



ข้อมูลฝึกและทดสอบมาจากคนเดียวกัน
แบ่งตามลำดับ *trial* ของแต่ละคำ; คำแต่ละคำถูกเก็บใน *word block* ของตนเอง

Independent Component Analysis (ICA)

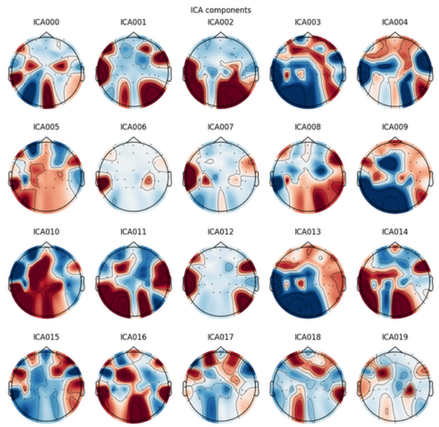
01 | Motivation

Within-subject ให้ผล Accuracy สูงมาก (80-90%+)

โมเดลเรียนรู้จากสมองหรือแอบจำกล้ามเนื้อ?

02 | The ICA Attempt

ใช้ ICA (25 Components) ร่วมกับ ICLabel



ตั้งใจแยก คลื่นสมองแท้ ออกจาก Muscle Artifacts เพื่อนำมา Re-train ดูผล

03 | Finding & Pivot

ยังไม่สามารถยืนยันว่าแยกแยะสัญญาณสมองออกจากกล้ามเนื้อได้เด็ดขาด

ไม่ว่าจะตัด IC ออกหรือไม่ Accuracy ก็ยังคงสูงใกล้เคียงเดิม

ย้ายไปทดสอบ Cross-subject เพื่อพิสูจน์หาสาเหตุที่แท้จริง

Overt & Mimed

💡 สรุป: Mimed มีแนวโน้มใช้เป็นฐานการฝึกเพื่อนำไปทำนาย Overt ได้ดีในระดับหนึ่ง แต่การฝึกจาก Overt มาทำนาย Mimed ยังไม่เห็นผลที่ได้อย่างมีประสิทธิภาพ

ย่านความถี่	Overt → Overt	**Overt → Mimed**	Mimed → Mimed	**Mimed → Overt**
4–30 Hz	93.12 ± 7.24%	**58.38 ± 12.00%**	96.31 ± 6.34%	**73.38 ± 17.05%**
30–45 Hz	92.63 ± 7.84%	**55.75 ± 13.49%**	96.38 ± 7.77%	**73.56 ± 15.66%**

แนวคิด: **Shared Core vs. Specific Features**

ฝึกด้วย Overt (Overt ➔ Mimed: ~57%)

- มีการสั่นของกล่องเสียงและการได้ยิน (Auditory feedback) ที่เป็น Dominant
- เมื่อไปทาย Mimed ที่ไม่มีเสียง โมเดลจึงขาดฟีเจอร์ทางลัด คะแนนจึงตกหนัก

ฝึกด้วย Mimed (Mimed ➔ Overt: ~73.5%)

- ไม่มีเสียงรบกวน บังคับให้โมเดลจับเฉพาะสัญญาณแกนกลาง
- สัญญาณแกนกลางนี้ยังคงมีอยู่ใน Overt ด้วย จึงถ่ายทอดความรู้ข้ามโหมดได้ดีกว่า

ผลเฉพาะ 4 class ที่เลือกมาเท่านั้น ยังไม่ได้ทดสอบทุก class

Summary

High Performance

Overt: ~88% - 93%
Mimed: ~88% - 97%

โมเดลจำแนกคำได้แม่นยำเมื่อทดสอบ within-subject

Analysis

ทุกย่านความถี่ (1-80 Hz) ให้ความแม่นยำสูงสม่ำเสมอ

สัญญาณปนเปื้อน: ICA แยกคลื่นสมองออกจากกล้ามเนื้อไม่ได้

สัญญาณ Mimed ถ่ายทอดไป Overt ได้ดีกว่าทางกลับกัน

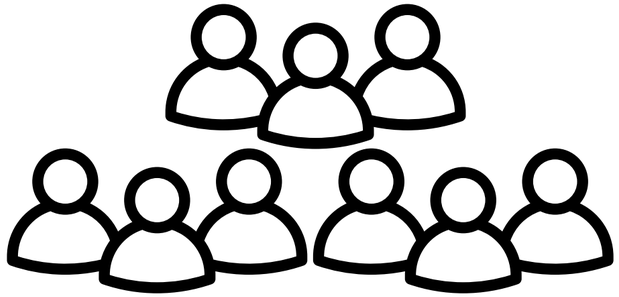
The Limitation

สงสัยว่าโมเดลอาจเรียนรู้จาก Subject Pattern

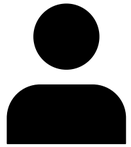
➔ ต้องพิสูจน์ต่อใน Cross-Subject

Cross-Subject

Strict Leave-One-Subject-Out: LOSO







นำข้อมูลของ 9 คนมาใช้ **Train** Model

อีก 1 คนที่เหลือไว้ **Test** สลับวนจนครบ 10 คน

2 Class (คู่คำ) chance 50%

ในแต่ละ *LOSO fold* โมเดลและ *scaler fit* จาก 9 คนฝึกเท่านั้น ทุกการ *Scaling, Feature Selection* จะคำนวณจาก 9 คนในชุด *Train* เท่านั้น โดยไม่ให้โมเดลเห็นข้อมูลหรือ *Labels* ของคนที่เป็น *Test* ล่วงหน้าเด็ดขาด

Approaches Explored

เมื่อดูครบ 80 ชุดคู่ในกลุ่มการบันทึกเดียวกัน (วันเดียวกัน) ผลยังใกล้ chance 50%

Pipeline	เฉลี่ยทุกคู่ ± SD ระหว่างคู่	SD ของ LOSO folds ภายในคู่โดยเฉลี่ย
4–30 Hz + Logistic	**51.44 ± 4.57%**	11.40 จุด
30–45 Hz + spatial LDA	**52.50 ± 4.89%**	13.19 จุด

- ค่าเฉลี่ยทุกคู่คำอยู่ที่ ~51–52% แทบไม่ต่างจากการเดาสุ่ม (50%)
- ความแปรปรวนสูงมาก (High Variance) มีคนที่ได้สูงมากๆ และต่ำมากๆ เช่นกัน

💡 สรุป: ยังไม่มีหลักฐานว่ามีโมเดล Machine Learning ที่จำแนกคำข้ามบุคคลได้อย่างเสถียรจาก Dataset นี้

Problems of Dataset

Day / Session Bias

[ผลกระโดดข้ามกลุ่มวัน]

การเลือกคู่คำ	Accuracy เฉลี่ยทุกคู่
อยู่ในกลุ่มวันเดียวกัน	**51.44%**
อยู่คนละกลุ่มวัน	**73.07%**

⚠️ คะแนนสูงขึ้นตอนเทียบคำที่อัดคนละวันอย่างมีนัยสำคัญ

Recording-group confound

[พิสูจน์ว่าโมเดลทายวันได้]

Train 8 คำ (9 คน) Test 2 คำใหม่ (คนที่ 10) ให้ model ทายว่าคำนั้นถูกเก็บในวันไหน

Mimed: 82.91 ± 17.8%
Overt: 74.41 ± 21.2%

⚠️ โมเดลแยกกลุ่มวันได้ แม้ไม่เคยเห็นคำและคนนั้น

High Subject Specificity

[ทำไมคนเดิมสูง แต่คนใหม่ต่ำ]

สัญญาณ EEG สามารถระบุตัวคนข้ามบล็อกได้แม่นยำถึง 82.6%

ความต่างระหว่างคำสอดคล้องกันดีมาก ภายในคนเดิม แต่ทิศทาง ไม่ตรงกันเลยระหว่างคน

→ **สัญญาณตัวบุคคลกลบสัญญาณคำพูด**

สัญญาณที่โมเดลใช้ทำนายไม่ใช่ Semantic ของคำพูด แต่เป็น Session/Day Drift, ลำดับบล็อก, รูปแบบ Cue และเอกลักษณ์เฉพาะตัวบุคคล (Subject Footprint) ที่ปนเปื้อนใน Dataset

Few-Shot Calibration

รูปแบบ Calibration	ข้อมูลที่ใช้ฝึก	Accuracy เฉลี่ยทุกคู่
Zero-Calibration	9 คนอื่นเท่านั้น	**51.44%**
Few-shot (ข้ามโหมด) (ทดสอบคนละ Block)	9 คนอื่น + คนใหม่ 20 trials/คำจากอีกโหมด	**77.80%**
Within Subject (ข้ามโหมด)	คนใหม่จากอีกโหมดเท่านั้น	**77.39%**

ใช้ข้อมูลอีกโหมดเพื่อแยกบล็อกฝึกกับบล็อกทดสอบ

Key Insights

- Zero-shot ใช้งานจริงไม่ได้หากไม่เห็นข้อมูลคนใหม่เลย
- ขอเพียง 20 trials/คำ จากผู้ใช้ตนใหม่ คะแนนพุ่งขึ้นอย่างมีนัยสำคัญ
- ข้อมูลคนอื่นแทบไม่ช่วย Transfer ทำให้คะแนนดีขึ้นเลย

💡 บทสรุปเชิงระบบ: BCI งานนี้จำเป็นต้องมีขั้นตอน Personal Calibration สั้นๆ รายบุคคล เนื่องจากโมเดลอาศัย Individual Feature ของผู้ใช้เป็นหลัก ข้อมูลจากผู้อื่นแทบไม่ส่งต่อ

Conclusion

Performance & Calibration

- Within-subject แม่นยำสูง (~90%+) แต่ Cross-subject Zero-calibration ไม่พร้อมใช้ (~52.5% เท่าเดาสุ่ม) จากปัญหา Subject Specificity และ Day Drift
- ทางออก BCI จำเป็นต้องมี Few-Shot Personal Calibration (เพียง 20 trials/คำ ได้ความแม่นยำฟื้นแตะ 77% – 86%)

Frequency & ICA

- ทุกย่านความถี่ (1–80 Hz) ให้ความแม่นยำสูงสม่ำเสมอ และ ICA ไม่สามารถคัดกรองหรือกด Accuracy ลงได้
- ชี้ให้เห็นว่าโมเดลอาจไม่ได้เรียนรู้จาก Semantics ของคลื่นสมองแท้จริง แต่จับสัญญาณรบกวนร่วม (Session/Day Bias และ Cue)

Overt & Mimed

- ถ่ายทอดความรู้ได้แบบทิศทางเดียว (Asymmetric):
  - Mimed -> Overt ทำงานได้ดี (~73.5%) จาก Core features
  - Overt -> Mimed ตกฮวบ (~57%) เนื่องจากโมเดลไปพึ่งพา Auditory feedback ทางลัด

💡 Recommendations

- สุ่มสลับคำระหว่าง Trial (Interleaved / Event-Related): เลิกเก็บแบบ Block คำเดิมซ้ำๆ รวดเดียว เพื่อตัดปัญหา Temporal Drift และความเหนื่อยล้าเฉพาะช่วงเวลา
- กระจายทุกคำให้บันทึกครบทุกวัน (Multi-Day Balancing): ให้ผู้เข้าร่วมพูดทุกคำในทุกวันของการทดลอง เพื่อกำจัด Day Bias ไม่ให้โมเดลจำสภาพแวดล้อมของวัน

Thank you