Brain Code Camp 2026 | Machine Learning | Signal Processing | EEG | Brain-Computer Interface | Neuroscience

Thai Overt & Mimed Speech EEG

เมื่อโมเดลอ่านคลื่นสมองทายคำพูดไทยได้ 90%+ ... แต่ความจริงกลับไม่ได้เป็นอย่างที่คิด: บทเรียนจากการทำ Speech BCI (Thai Overt & Mimed Speech EEG)

เฟิร์ม — นนทพัทธ์ เอื้อตรงจิตต์ (Nontapat Auetrongjit)
นิสิต สาขาวิศวกรรมคอมพิวเตอร์และเทคโนโลยีดิจิทัล (CEDT) จุฬาลงกรณ์มหาวิทยาลัย

พฤศจิกายน 2026 (Published Nov 1, 2026) 7 min read อ่านต้นฉบับบน Medium



Github: https://github.com/nontaphatfirm/Thai-Overt-Mimed-Speech-EEG
Brain Code Camp: https://braincode101.github.io/

EXECUTIVE SUMMARY **บทสรุปสำคัญของโครงการวิจัย (TL;DR)**

โครงการนี้สำรวจความเป็นไปได้ในการจำแนกคำภาษาไทยจากสัญญาณคลื่นไฟฟ้าสมอง (EEG) ทั้งขณะพูดออกเสียง (**Overt Speech**) และขยับปากโดยไม่ออกเสียง (**Mimed Speech**) จากผลลัพธ์ช่วงแรกที่ดูเหมือนโมเดลจะทายคำในคนเดิมได้แม่นยำถึง **88–97%** นำไปสู่การตั้งคำถามและพิสูจน์เชิงลึกจนพบว่า คะแนนที่สูงเหล่านั้นปนเปื้อนไปด้วย **ความต่อเนื่องภายในบล็อกการบันทึก (Block Continuity), ความต่างของกลุ่มวันบันทึก (Session/Day Confound) และเอกลักษณ์เฉพาะบุคคล (Subject Specificity)** เมื่อทดสอบข้ามคนอย่างรัดกุม (Strict LOSO) คะแนนจึงตกลงมาใกล้เคียงการเดาสุ่ม (**~51–52%**) ก่อนจะพบว่าวิธีที่พอใช้งานได้จริงในเชิงระบบคือการทำ **Few-Shot Personal Calibration** สั้นๆ รายบุคคล

Project Background

สวัสดีครับ ผม **เฟิร์ม — นนทพัทธ์ เอื้อตรงจิตต์ (Nontapat Auetrongjit)** นักศึกษา สาขาวิศวกรรมคอมพิวเตอร์และเทคโนโลยีดิจิทัล (CEDT) จุฬาลงกรณ์มหาวิทยาลัย บทความนี้เป็นการสรุปผลงานและบทเรียนสำคัญจากโปรเจกต์ที่ผมได้พัฒนาขึ้นภายใต้โครงการ **Brain Code Camp (BCC) 2026**

จุดเริ่มต้นของโปรเจกต์นี้มาจากปัญหาที่ว่า **การสื่อสารด้วยเสียงอาจทำไม่ได้สำหรับผู้ที่มีข้อจำกัดด้านการพูด** เช่น ผู้ป่วยโรคหลอดเลือดสมอง โรคกล้ามเนื้ออ่อนแรง (ALS) หรือผู้ที่สูญเสียความสามารถในการเปล่งเสียง เทคโนโลยี **Brain-Computer Interface (BCI)** ด้วยสัญญาณ **EEG (Electroencephalography)** จึงเป็นแนวทางหนึ่งที่น่าสนใจในการศึกษาว่า *"ถ้าให้คิดคำในหัว สัญญาณคลื่นสมอง (EEG) จะบอกได้ไหมว่าเขากำลังจะพูดคำว่าอะไร?"*

> โครงการนี้จึงเริ่มต้นจากความต้องการพัฒนาพื้นฐานของ **ระบบสื่อสารคำภาษาไทยโดยวิเคราะห์คลื่นสัญญาณสมอง** เพื่อดูว่าเราจะสามารถถอดรหัสคำศัพท์พื้นฐานในชีวิตประจำวันจากสัญญาณ EEG ได้มากน้อยแค่ไหน

Objective / Goal

> เป้าหมายหลักของงานนี้ไม่ใช่แค่การสร้างโมเดลให้ได้ตัวเลข Accuracy สูงที่สุด แต่คือ **การประเมินอย่างรอบคอบว่าสัญญาณ EEG ระหว่างการพูดแบบ ออกเสียง (Overt) และ ขยับปาก/ลิ้นโดยไม่ออกเสียง (Mimed) ใช้จำแนกคำภาษาไทยได้เพียงใด ทั้งในคนเดิมและคนใหม่ พร้อมระบุข้อจำกัดของผลลัพธ์ที่อาจเกิดจากเงื่อนไขการบันทึกและสัญญาณรบกวนบน Dataset**

เราตั้งคำถามวิจัยหลักไว้ 3 ข้อ:

1. **จำแนกคำได้ดีและเสถียรแค่ไหน?** เปรียบเทียบระหว่างการฝึกและทดสอบในคนเดิม (**Within-subject**), การทดสอบข้ามคนแบบไม่เคยเห็นข้อมูลคนใหม่เลย (**Cross-subject แบบ Strict LOSO**), และกรณีที่มีตัวอย่างจากคนใหม่เล็กน้อย (**Few-shot Calibration**)
2. **ย่านความถี่และการเตรียมสัญญาณส่งผลอย่างไร?** เปรียบเทียบย่านความถี่ต่างๆ ของ EEG และการแยกสัญญาณรบกวนด้วย **ICA (Independent Component Analysis)** โดยตรวจสอบว่าคะแนนที่เปลี่ยนไปตีความได้แค่ไหน
3. **Overt กับ Mimed ใช้แทนกันได้ไหม?** เปรียบเทียบผลของสองโหมด และทดสอบการฝึกโมเดลจากโหมดหนึ่งเพื่อนำไปทำนายในอีกโหมดหนึ่ง (**Cross-mode Transfer**)

Dataset & Scope

> ในงานนี้เราใช้ Public Dataset: **Thai Overt-Mimed Speech EEG Dataset บน Mendeley Data** โดยมุ่งเน้นวิเคราะห์ข้อมูลเพื่อตรวจสอบความเป็นไปได้ในการจำแนกคำศัพท์:

โครงสร้างข้อมูลและกลุ่มคำ: ข้อมูลประกอบด้วยผู้เข้าร่วม 20 คน แบ่งเป็น 2 ชุด (Cohorts) ชุดละ 10 คน แต่ละชุดมีคำศัพท์ภาษาไทย 10 คำ (รวมทั้งหมด 20 คำ) โดยอ้างอิงตามรายละเอียดบน Mendeley Data และการสอบถามเพิ่มเติมกับทีมผู้วิจัยเจ้าของชุดข้อมูล (Personal Communication) คำศัพท์ในแต่ละชุดถูกแบ่งบันทึกเป็น 2 กลุ่มกลุ่มละ 5 คำ (5 คำแรก และ 5 คำหลัง):

- **ชุดที่ 1 (Cohort 1 จำนวน 10 คน — `word_01` ถึง `word_10`):**
  - *กลุ่มที่ 1:* `1. เปิดไฟ` , `2. ปิดไฟ` , `3. อุจจาระ` , `4. ปัสสาวะ` , `5. หิวข้าว`
  - *กลุ่มที่ 2:* `6. หิวน้ำ` , `7. เศร้า` , `8. กลัว` , `9. โกรธ` , `10. ดีใจ`

- **ชุดที่ 2 (Cohort 2 จำนวน 10 คน — `word_11` ถึง `word_20`):**
  - *กลุ่มที่ 1:* `11. เข็ดตัว` , `12. ใช่` , `13. ไม่` , `14. หมอ` , `15. ปวด`
  - *กลุ่มที่ 2:* `16. หัว` , `17. ขา` , `18. แขน` , `19. หลัง` , `20. คอ`

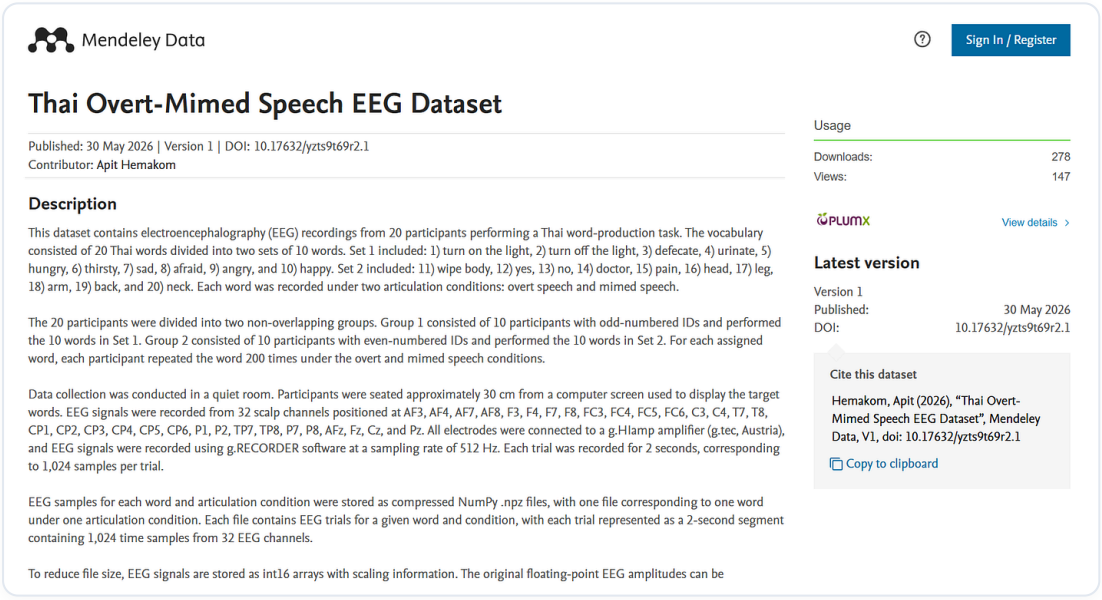
โหมดการพูด (2 Modes):

- **Overt Speech:** พูดออกเสียงคำศัพท์ตามปกติ
- **Mimed Speech:** ขยับปากและลิ้นเสมือนพูดคำนั้นโดยไม่ออกเสียง (Silent Articulation)

Dimensional และ Property ของสัญญาณ: บันทึกสัญญาณ EEG **32 ช่องสัญญาณ** (มาตรฐาน 10–20 system), Sampling Rate **512 Hz**, แต่ละ Trial ยาว **2 วินาที** (1,024 samples) มีจำนวน **200 trials ต่อคำ/โหมด/คน** โดยข้อมูลของแต่ละคำถูกจัดเก็บเรียงเป็นบล็อกต่อเนื่องกันในไฟล์ `.npz` รวมทั้งหมด 80,000 trials (40 ไฟล์)

> *Analytical Scope & Data Notes:*

- ไฟล์ `.npz` ที่เผยแพร่บนระบบไม่ได้ระบุรหัสผู้เข้าร่วม (`subject_id`) มาโดยตรง ในการประเมินเราจึงแบ่งข้อมูลแถวต่อเนื่องทุกๆ 200 Trials (`0:200` , `200:400` , ..., `1800:2000`) เป็น **10 Provisional Participant Slots** ต่อชุดผู้เข้าร่วม โดยตั้งสมมติฐานว่าลำดับผู้เข้าร่วมสอดคล้องกันข้ามไฟล์ในชุดเดียวกัน
- เนื่องจาก Dataset นี้ยังไม่มีการเผยแพร่ Public Paper หรือ Methodology Documents อย่างเป็นทางการ ดังนั้นวิธีการเก็บข้อมูล ลำดับและชื่อคำศัพท์จะอ้างอิงจากคำอธิบายอย่างเป็นทางการบน Mendeley Data และ Personal communication กับทีมวิจัย โดยแยกกลุ่ม 5 คำแรกและ 5 คำหลังออกจากกันอย่างชัดเจน เพื่อป้องกันความคลาดเคลื่อนในการจับคู่คำ



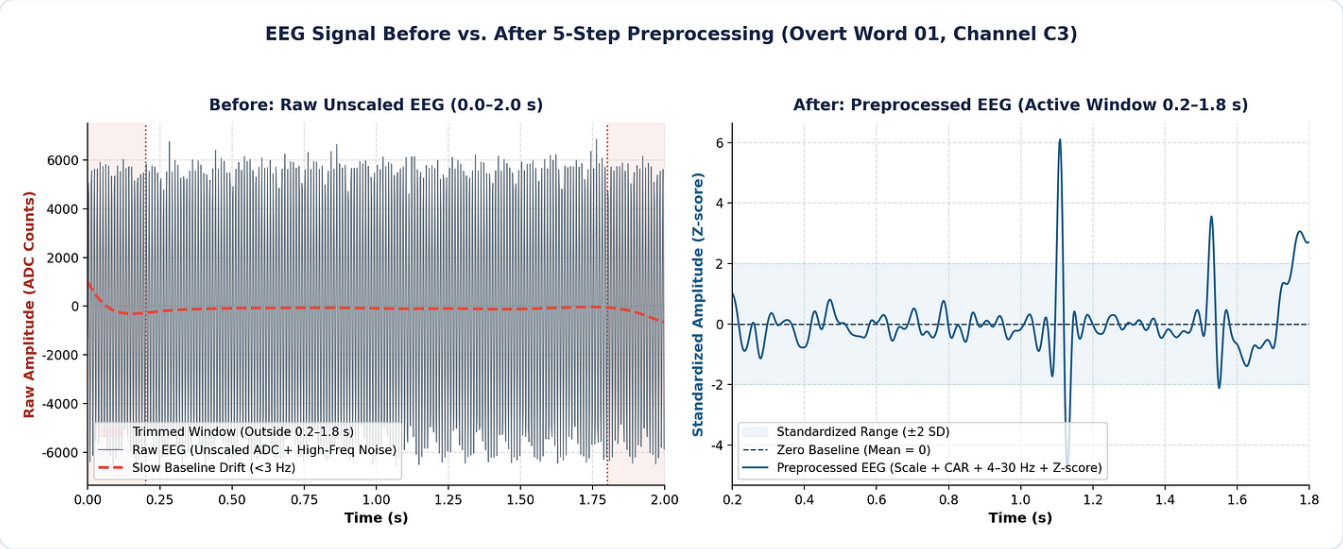
รูปภาพ: ภาพรวมชุดข้อมูล Thai Overt-Mimed Speech EEG บน Mendeley Data

Preprocessing

> ก่อนนำสัญญาณเข้าสู่โมเดล ข้อมูลดิบ (Raw EEG) ซึ่งอยู่ในรูปค่า ADC counts ที่มีทั้งไฟกระแสตรง (DC offset), การลอยของเส้นฐาน (Baseline drift) และสัญญาณรบกวนร่วมทุกช่อง จะต้องผ่าน Pipeline preprocessing 5 ขั้นตอนดังนี้:

1. **Scale Restoration (`eeg × scale`):** คูณค่าสัญญาณดิบด้วยตัวคูณ `scale` ประจำแต่ละ trial เพื่อคืนค่าแรงดันไฟฟ้าจริงในหน่วยโวลต์หรือไมโครโวลต์ (V/μV)
2. **Spatial Re-referencing:** ขจัดสัญญาณรบกวนที่ปรากฏเหมือนกันทุกช่อง (Common-mode noise) ด้วย **Common Average Reference (CAR)** (นำค่าเฉลี่ยของทั้ง 32 ช่องในแต่ละจุดเวลามาลบออก) และลบค่าเฉลี่ยรายช่อง (Channel Demeaning)

3. **Frequency Selection:** กรองย่านความถี่ที่สนใจด้วย **Time-domain Butterworth Bandpass Filter** (สำหรับโมเดล `EEGNet`) หรือสกัดค่าพลังงานความถี่ด้วย **Hann-windowed FFT Log-bandpower** (สำหรับโมเดลเชิงเส้นอย่าง Logistic Regression และ LDA)
4. **Time Windowing:** เลือกตัดเฉพาะช่วงเวลา **0.2–1.8 วินาที** (ตัวอย่างที่ `102:922` ที่ 512 Hz) เพื่อลดผลกระทบของช่วงต้น trial (จังหวะกระตุ้นด้วยภาพ/เสียง Cue) และช่วงท้าย trial
5. **Signal Normalization:** ปรับสเกลสัญญาณให้เป็นมาตรฐานเดียวกันด้วย **Per-trial Z-score** (สำหรับงาน Within-subject `EEGNet`) หรือใช้ **`StandardScaler` ที่ fit จากชุด Train เท่านั้น** (สำหรับงาน Cross-mode และ Strict LOSO เพื่อป้องกัน Data Leakage)



รูปภาพ: Pipeline การเตรียมสัญญาณ EEG 5 ขั้นตอน (eeg_preprocessing_before_after.png)

Model Selection & Tuning Hyperparameter

- **Within-Subject (`EEGNet`):** เลือกใช้สถาปัตยกรรม Compact CNN สำหรับ EEG โดยเฉพาะ (Lawhern et al., 2018) ที่ใช้ Depthwise และ Separable Convolutions สกัดฟีเจอร์ทั้งมิติเวลาและมิติช่องสัญญาณด้วยจำนวนพารามิเตอร์ที่น้อยมาก (F1=8,D=2, Kernel length =256 หรือ 500 ms ที่ 512 Hz, Dropout =0.25) ช่วยลดการ Overfit ได้ดี โดยฝึกด้วย Optimizer `Adam(lr=1e-3)`, Cross-Entropy Loss, Batch size 32, จำนวน 100 Epochs ร่วมกับ Per-trial Z-score
- **Cross-Mode & Cross-Subject (Linear Baselines):** เมื่อทดสอบข้ามคน สัญญาณมีความแปรปรวนระหว่างบุคคลสูงมาก โมเดลซับซ้อนมัก Overfit กับเอกลักษณ์เฉพาะตัวบุคคล เราจึงเลือกใช้โมเดลเชิงเส้นบนฟีเจอร์ FFT Log-bandpower เพื่อให้ได้ Baseline ที่เสถียร ตรวจสอบซ้ำได้รวดเร็ว (180 คู่คำ × 10 Folds) และแปลผลได้ตรงไปตรงมา:
  - **Logistic Regression (C=0.1):** ปรับจูน L2 Regularization (C=0.1) เพื่อควบคุมค่าน้ำหนักฟีเจอร์จาก 32 ช่องสัญญาณไม่ให้จำสัญญาณรบกวนข้ามคน
  - **Shrinkage LDA (`shrinkage="auto"`):** ใช้เทคนิค Ledoit-Wolf Analytic Shrinkage ปรับประมาณ Covariance matrix อัตโนมัติ แก้ปัญหา Matrix ill-conditioned จากความสัมพันธ์เชิงพื้นที่ของขั้วสัญญาณ EEG

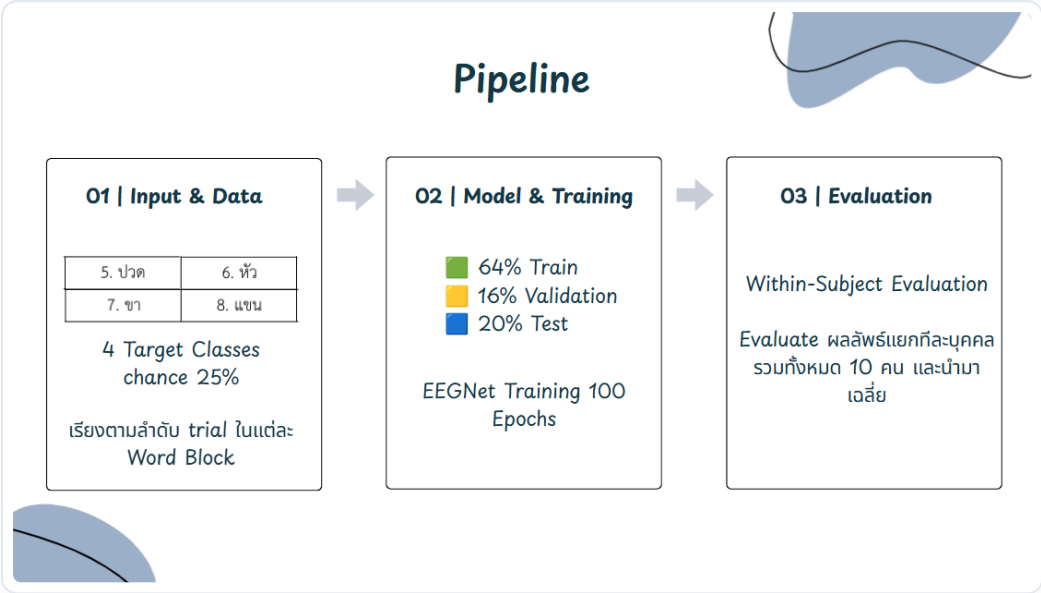
Within-Subject

1. Pipeline การทดลอง Within-Subject

ในเฟสแรก เราต้องการดูว่าหากฝึกโมเดลแยกเฉพาะบุคคล โมเดลจะจำแนกคำได้ดีแค่ไหน:

- **01 | Input & Data:** เลือกคำทดสอบ 4 คลาส (`words = [5, 6, 7, 8]`, โอกาสทายถูกจากการเดาสุ่ม Chance = **25%**) โดยแบ่งข้อมูลเรียงตามลำดับเวลา (Chronological split) ภายในแต่ละ Word Block ของแต่ละคน

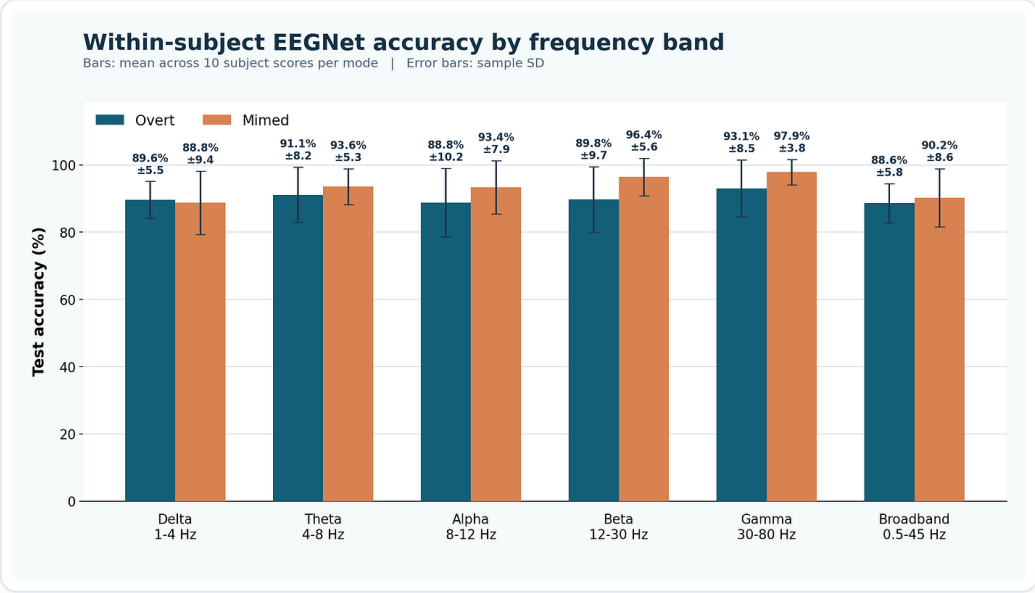
- **02 | Model & Training:** แบ่งข้อมูลเป็น **64% Train / 16% Validation / 20% Test** แล้วฝึกด้วยสถาปัตยกรรม Deep Learning สำหรับสัญญาณสมองอย่าง `EEGNet` เป็นจำนวน **100 Epochs**
- **03 | Evaluation:** ประเมินผลลัพธ์แยกทีละบุคคล รวมทั้งหมด 10 คน แล้วนำคะแนน Test Accuracy มาหาค่าเฉลี่ยและส่วนเบี่ยงเบนมาตรฐาน (Mean ± SD)



รูปภาพ: แผนผังขั้นตอนการทดลองและประเมินผลแบบ Within-Subject (01 Input & Data, 02 Model & Training EEGNet, 03 Evaluation)

2. ผลลัพธ์แยกตามย่านความถี่ (Frequency Analysis)

เมื่อทดลองกรองความถี่แยกเป็น 6 ย่าน พบผลลัพธ์ที่น่าสนใจมาก เพราะโมเดลทำคะแนนเฉลี่ยได้สูงเกือบ **90% ขึ้นไปในทุกย่านความถี่** ทั้งโหมดพูดออกเสียงและไม่ออกเสียง:



รูปภาพ: ผลลัพธ์แยกตาม 6 ย่านความถี่ด้วยโมเดล EEGNet (within_subject_eegnet_frequency_accuracy.png)

3. ความกังวลเรื่องสัญญาณกล้ามเนื้อ และการพิสูจน์ด้วย ICA

การที่โมเดลได้ Accuracy สูงถึง **88–97%** ในทุกย่านความถี่ (โดยเฉพาะย่านความถี่สูงอย่าง Beta และ Gamma) ทำให้เราเกิดคำถามสำคัญขึ้นมาทันที:

> *“โมเดลเรียนรู้จากคลื่นสมองจริงๆ หรือแอบจำสัญญาณกล้ามเนื้อ (EMG) ตอนขยับปากพูดกันแน่?”*

เราจึงทำการทดลองต่อด้วย **Independent Component Analysis (ICA)**:

- **วิธีการ:** ใช้ **Picard ICA (25 Components)** ร่วมกับโมเดลอัตโนมัติ `ICLabel` แยกองค์ประกอบสัญญาณของแต่ละคน เพื่อคัดทิ้งองค์ประกอบที่เป็นการกะพริบตา (Eye blink), หัวใจเต้น (Heart beat), สัญญาณรบกวนสายไฟ/ช่องสัญญาณ, รวมถึงองค์ประกอบที่มีความน่าจะเป็นของกล้ามเนื้อ (`Muscle > 30%`) หรือมีความเป็นคลื่นสมองต่ำ (`Brain ⩽ 40%`) จากนั้นจึงนำสัญญาณที่คลีนแล้วในช่วง `0.5–30 Hz` ไปฝึก `EEGNet` ใหม่อีกครั้ง
- **สิ่งที่พบ:** ไม่ว่าจะตัดองค์ประกอบ IC ที่คาดว่าเป็นกล้ามเนื้อออกหรือไม่ **Accuracy ก็ยังคงสูงใกล้เคียงเดิม (~87–90%)**
- **ข้อสรุปและจุดเปลี่ยน:** ผลลัพธ์นี้ยังไม่สามารถยืนยันได้ว่าเราแยกสัญญาณสมองออกจากกล้ามเนื้อได้เด็ดขาด และที่สำคัญกว่านั้น ข้อมูลแต่ละคำถูกเก็บต่อเนื่องกัน 200 ครั้งในบล็อกเดียว (`Word Block`) การแบ่ง Train 64% แรก และ Test 20% ท้ายในบล็อกเดียวกัน อาจทำให้โมเดลจำ **สภาพของบล็อกหรือช่วงเวลานั้น (Within-block continuity)** แทนที่จะจำคำพูด เราจึงต้องย้ายไปทดสอบแบบ **Cross-subject** เพื่อพิสูจน์หาสาเหตุที่แท้จริง

4. Overt กับ Mimed ใช้แทนกันได้ไหม? (Within-Subject Cross-Mode Transfer)

เราได้ทดสอบการถ่ายโอนความรู้ข้ามโหมดการพูดภายในคนเดิม (4 คลาส `words = [5, 6, 7, 8]` , Chance = 25%) โดยสกัดฟีเจอร์ `CAR + 0.2–1.8 s Hann FFT log-bandpower + train-only StandardScaler + LogisticRegression(C=0.1)` (ใช้ 160 trials แรกเป็น Train และ 40 trials ท้ายเป็น Test ต่อคำ):

Frequency Band	Overt → Overt	**Overt → Mimed**	Mimed → Mimed	**Mimed → Overt**
4–30 Hz	93.12 ± 7.24%	**58.38 ± 12.00%**	96.31 ± 6.34%	**73.38 ± 17.05%**
30–45 Hz	92.63 ± 7.84%	**55.75 ± 13.49%**	96.38 ± 7.77%	**73.56 ± 15.66%**

รูปภาพ: ผลการถ่ายโอนความรู้ข้ามโหมดการพูด (Within-Subject Cross-Mode Transfer: Overt vs Mimed)

ผลลัพธ์แสดงให้เห็นถึง **ความไม่สมมาตร (Asymmetric Transfer)** ที่น่าสนใจ:

- **ฝึกด้วย Overt ไปทาย Mimed (`Overt → Mimed` : ~56–58%):** คะแนนตกลงอย่างหนัก สมมติฐานหนึ่งเชิงระบบคือ ในโหมดพูดออกเสียงมีสัญญาณจากการสั่นของกล่องเสียงและการได้ยินเสียงตัวเอง (Auditory feedback) ที่เด่นชัด (Dominant) เมื่อนำไปทายโหมด Mimed ที่ไม่มีเสียง โมเดลจึงขาดฟีเจอร์ทางลัดที่ใช้พึ่งพา
- **ฝึกด้วย Mimed ไปทาย Overt (`Mimed → Overt` : ~73.5%):** ให้ผลลัพธ์ที่ดีกว่าอย่างชัดเจน เพราะการไม่มีเสียงพูดบังคับให้โมเดลต้องจับเฉพาะสัญญาณแกนกลาง (Shared Core Features) ของการตั้งใจพูดและขยับปาก ซึ่งสัญญาณแกนกลางนี้ยังคงปรากฏอยู่ในโหมด Overt ด้วย

(หมายเหตุขอบเขตการตีความ: การทดลองนี้ทำบนชุดคำ 4 คลาสที่เลือกมา และเนื่องจากแต่ละคำยังผูกอยู่กับบล็อกการบันทึกของตนเอง คะแนนจึงสะท้อนความสอดคล้องของบล็อกและโหมดในคนเดิม ยังไม่สามารถสรุปแยกเป็นกลไกทาง Neuroscience เดี่ยวๆ ได้โดยไม่มีข้อมูลข้ามเซสชันที่สลับลำดับคำ)

5. สรุปผลระยะที่ 1 (Within-Subject Summary)

1. **High Performance:** เมื่อฝึกและทดสอบในคนเดิม โมเดลจำแนกคำได้แม่นยำมาก (Overt `~88–93%` , Mimed `~88–97%`)
2. **Analysis:** ทุกย่านความถี่ (`1–80 Hz`) ให้ความแม่นยำสูงสม่ำเสมอ การใช้ ICA ไม่สามารถกดคะแนนลงได้ และโหมด Mimed ถ่ายทอดไป Overt ได้ดีกว่าทางกลับกัน

3. **The Limitation:** เรายังสงสัยว่าโมเดลอาจเรียนรู้จาก **Subject Pattern** หรือ **Block/Session Confound** จึงต้องพิสูจน์ต่อในระดับ **Cross-Subject**

Cross-Subject

1. Strict Leave-One-Subject-Out (LOSO)

เพื่อตอบคำถามว่าโมเดลสามารถนำไปใช้กับผู้ป่วยหรือผู้ใช้คนใหม่ได้ทันทีโดยไม่ต้องเก็บข้อมูลฝึกใหม่ (Zero-calibration) หรือไม่ เราได้ออกแบบการประเมินแบบ **Strict 10-Fold LOSO**:

- นำข้อมูลของ **9 คน (9 Slots)** มาใช้ **Train Model** และเก็บ **อีก 1 คนที่เหลือไว้ Test** สลับวนจนครบทั้ง 10 คนในแต่ละ Cohort
- ปรับโจทย์เป็น **2 Classes (จับคู่คำ 2 คำ, โอกาสสุ่ม Chance = 50%)** เพื่อวัดความสามารถในการแยกแยะขั้นพื้นฐานที่สุดอย่างโปร่งใส
- **ป้องกัน Data Leakage:** ในแต่ละ LOSO fold การคำนวณค่าสถิติทั้งหมด ไม่ว่าจะเป็น `StandardScaler` หรือการคัดเลือกฟีเจอร์ จะถูกคำนวณจากข้อมูลของ 9 คนในชุด Train เท่านั้น โดยไม่ให้โมเดลเห็นข้อมูลหรือ Labels ของคนที่เป็น Test ล่วงหน้าเด็ดขาด



รูปภาพ: แผนผังการประเมินผลข้ามบุคคลแบบรัดกุม Strict 10-Fold Leave-One-Subject-Out (LOSO)

2. ผลลัพธ์เมื่อสแกนครบทุกคู่คำในกลุ่มวันเดียวกัน (Approaches Explored)

เราทำการสแกนคู่คำทั้งหมดที่ถูกบันทึกในกลุ่มการบันทึกเดียวกัน (วันเดียวกัน / `same_half=True`) รวมทั้งสิ้น **80 ชุดคู่คำ** (ครอบคลุมทั้ง 2 Cohorts และทั้ง 2 โหมด):

Pipeline (Zero-Calibration)	Mean across pairs ± Inter-pair SD (80 pairs)	Average intra-pair LOSO fold SD	Per-fold score range (Min-Max)
4–30 Hz + Logistic Regression	**51.44 ± 4.57%**	11.40 points	0.75% - 99.00%
30–45 Hz + Spatial Shrinkage LDA	**52.50 ± 4.89%**	13.19 points	0.00% - 100.00%

รูปภาพ: ผลการจำแนกคำข้ามบุคคล 80 คู่คำในกลุ่มวันเดียวกัน (ความแม่นยำเฉลี่ย ~51–52%)

สิ่งที่เกิดขึ้น:

- เมื่อควบคุมให้เปรียบเทียบเฉพาะคำที่อัดในกลุ่มวันเดียวกัน ค่าเฉลี่ยของทุกคู่คำอยู่ที่ **~51–52% ซึ่งแทบไม่ต่างจากการเดาสุ่ม (50%)**

- ความแปรปรวนระหว่างบุคคลสูงมาก (High Variance) มีบางคนที่โมเดลทายได้สูงมาก และมีบางคนที่ทายผิดเกือบทั้งหมด
- **บทสรุป:** จาก Pipeline ที่ทดสอบ **ยังไม่มีหลักฐานว่ามีโมเดล Machine Learning ที่จำแนกคำข้ามบุคคลแบบ Zero-calibration ได้อย่างเสถียรจาก Dataset นี้**

Root Cause Analysis (Problems of Dataset)

เนื่องจากผลลัพธ์สองการทดลองแรกถึงต่างกันราวฟ้ากับเหว เราจึงได้ตั้งสมมุติฐานและตรวจสอบเชิงลึก จนค้นพบ **3 ปัญหาโครงสร้างสำคัญของ Dataset**:

1. Day / Session Bias

เมื่อเราลองเปรียบเทียบผลการจำแนกคู่คำด้วย Pipeline `4–30 Hz + Logistic Regression` ระหว่างคู่คำที่อัดในกลุ่มวันเดียวกัน กับคู่คำที่อัดคนละกลุ่มวัน:

Word-Pair Selection	Number of Pairs	Mean Accuracy across Pairs ± SD
Within the same session group (same_half=True)	80 pairs	**51.44 ± 4.57%**
Across different session groups (same_half=False)	100 pairs	**73.07 ± 8.31%**

รูปภาพ: ผลกระทบของ Day / Session Bias (Same Half 51.44% vs Different Half 73.07%)

คะแนนกระโดดจาก **51.44% ไปเป็น 73.07%** ทันทีเมื่อเทียบคำที่อัดคนละวัน นี่คือหนึ่งในปัญหาของ Dataset เพราะถ้าเราไม่แยกแยะเรื่องกลุ่มการบันทึก เราจะเข้าใจผิดว่าโมเดลเก่งขึ้น ทั้งที่จริงแล้วโมเดลกำลังแยก **ความต่างของเซสชัน/วันบันทึก** ไม่ใช่ความหมายของคำพูด

2. Recording-Group Confound

จากข้อ 1 เราจึงตั้งการทดลองควบคุมในชุดคำที่ `11–20`:

- นำข้อมูล **8 คำ จาก 9 คน** มาฝึกให้โมเดลทายว่า สัญญาณนั้นมาจาก *“กลุ่ม 5 คำแรก (Day 1)”* หรือ *“กลุ่ม 5 คำหลัง (Day 2)”*
- นำไปทดสอบกับ **2 คำใหม่ที่ไม่เคยเห็นมาก่อน ของคนที่ 10 ที่ไม่เคยเห็นมาก่อน**
- **ผลลัพธ์:** โมเดลสามารถทายกลุ่มวันบันทึกได้แม่นยำถึง **`82.91 ± 17.8%` ในโหมด Mimed** และ **`74.41 ± 21.2%` ในโหมด Overt**
- นี่คือหลักฐานว่า มีสัญญาณของสภาพแวดล้อมการบันทึก (Session/Day Drift) ที่ส่งต่อข้ามคำและข้ามคนได้อย่างชัดเจน

3. High Subject Specificity (ทำไมคนเดิมสูง แต่คนใหม่ต่ำ?)

เราทดสอบต่อด้วยการวัดเอกลักษณ์ของสัญญาณรายบุคคล (Slot Fingerprint) ในคู่คำกลุ่มวันเดียวกัน (`4–30 Hz`):

- เมื่อฝึกตัวจำแนกแบบ Nearest-centroid จากบล็อกคำหนึ่ง เพื่อไป **ทายว่าสัญญาณในอีกบล็อกคำหนึ่งเป็นของใคร (จาก 10 คน, โอกาสสุ่ม 10%)** โมเดลสามารถระบุตัวคนข้ามบล็อกได้แม่นยำถึง **`82.6%`**

- นอกจากนี้ เมื่อวิเคราะห์ทิศทางความต่างระหว่างคำคู่เดียวกัน (Word Contrast Vector: คำ B ลบ คำ A) พบว่าภายในคนเดิม ครึ่งแรกกับครึ่งหลังของบล็อกมีทิศทางสอดคล้องกันดีมาก (`mean cosine = 0.702`) แต่เมื่อเทียบทิศทางเดียวกันระหว่างคนละคน ค่าความสอดคล้องกลับใกล้ศูนย์ (`mean pairwise cosine = 0.010`)
- สรุปได้ชัดเจนว่า **สัญญาณประจำตัวบุคคลและสถานะการบันทึก (Subject & Block Footprint) มีขนาดใหญ่และกลบสัญญาณความต่างของคำพูดไปหมด** และแต่ละคนก็มีแพทเทิร์นความต่างระหว่างคำที่ไม่ไปในทิศทางเดียวกัน

> สัญญาณที่โมเดลนำมาใช้ทำนายได้ดีในตอนแรกจึงไม่ใช่ Semantic ของคำพูดเพียงอย่างเดียว แต่อาจปนเปื้อนไปด้วย **Session/Day Drift, ลำดับบล็อก (Block Continuity), รูปแบบ Cue และเอกลักษณ์เฉพาะตัวบุคคล (Subject Footprint)**

Few-Shot Personal Calibration

เมื่อเราทราบว่าปัญหาหลักคือความจำเพาะเจาะจงของสัญญาณในแต่ละบุคคล (High Subject Specificity) เราเลยลองทดสอบต่อว่า **ถ้าเรายอมให้ผู้ใช้คนใหม่อัดเสียง/ขยับปากพูดเป็นตัวอย่างสั้นๆ เพื่อปรับจูนระบบ (Calibration) ก่อนใช้งาน ผลลัพธ์จะกลับมาใช้งานได้จริงไหม**

เราได้ทดสอบ **Few-Shot Calibration** บนคู่คำในกลุ่มวันเดียวกันทั้ง **80 คู่** (โอกาสสุ่ม 50%) โดยขอข้อมูลที่มี Label จากผู้ใช้คนใหม่เพียง **20 trials ต่อคำ**:

Calibration Setup	Training Data	Test Set	Average Accuracy Across Pairs ± SD
Zero-Calibration (zero_low_logistic)	9 other subjects only (4–30 Hz)	200 trials/word from new subject	51.44 ± 4.57%
Cross-Modal Few-Shot + Other Subjects (source_plus_opposite_low)	9 other subjects + 20 trials/word from new subject (other modality) (4–30 Hz)	200 trials/word from new subject (different block from calibration)	77.80 ± 10.87%
Within-Subject Cross-Modal Few-Shot (opposite_target_only_low)	20 trials/word from new subject (other modality only) (4–30 Hz, trained from scratch)	200 trials/word from new subject (different block from calibration)	77.39 ± 10.95%
Within-Block Few-Shot (target_first20)	First 20 trials/word from new subject in the same block only (trained from scratch)	Remaining 180 trials/word in the same block	86.13 ± 6.83%

รูปภาพ: ผลการทำ Few-Shot Personal Calibration (Zero-shot vs 20 Trials รายบุคคล)

Key Insights:

1. **Zero-shot ใช้งานจริงไม่ได้** หากโมเดลไม่เคยเห็นข้อมูลของผู้ใช้คนใหม่เลย (`51.44%`)
2. **ขอเพียง 20 trials/คำ จากผู้ใช้คนใหม่ คะแนนพุ่งขึ้นอย่างมีนัยสำคัญ:**
   - หากใช้ 20 trials จากอีกโหมด (ซึ่งอยู่คนละบล็อกการบันทึกกับชุดทดสอบ) คะแนนเฉลี่ยพุ่งขึ้นจาก `51.44%` มาอยู่ที่ **`77.39% – 77.80%`**
   - หากใช้ 20 trials แรกในบล็อกเดียวกันมาฝึก คะแนนแตะ **`86.13%`** *(แต่ต้องระวังว่าคะแนนส่วนนี้ได้รับผลจากความต่อเนื่องภายในบล็อกเดียวกันด้วย)*
3. **ข้อมูลของคนอื่นแทบไม่ช่วย Transfer เลย:** เมื่อเทียบระหว่างการใช้เฉพาะข้อมูลคนใหม่ 20 trials จากอีกโหมด (`77.39%`) กับการเอาข้อมูล 9 คนอื่นมาช่วยผสมด้วย (`77.80%`) พบว่าคะแนนต่างกันเพียง **`+0.41%`** เท่านั้น ชี้ให้เห็นว่าในระบบนี้ โมเดลพึ่งพาฟีเจอร์เฉพาะบุคคลของผู้ใช้คนนั้นเป็นหลัก

Conclusion & Recommendations

Conclusion

1. **Performance & Calibration:**
   - การประเมินแบบ Within-subject ให้ความแม่นยำสูง (`~90%+`) แต่การนำไปใช้ข้ามคนทันทีแบบ Cross-subject Zero-calibration ยังไม่พร้อมใช้งาน (`~51.4–52.5%` เท่าการเดาสุ่ม) คาดว่ามาจากปัญหา Subject Specificity และ Day Drift
   - หากต้องการใช้ Dataset นี้ในเชิงระบบสำหรับ BCI **จำเป็นต้องมีขั้นตอน Few-Shot Personal Calibration สั้นๆ รายบุคคล** โดยใช้ข้อมูลเพียง 20 trials/คำ ก็สามารถดึงความแม่นยำกลับมาที่ระดับ **`77% – 86%`** ได้
2. **Frequency & ICA:**
   - ทุกย่านความถี่ (`1–80 Hz`) ให้ความแม่นยำสูงสม่ำเสมอในระดับคนเดิม และการใช้ ICA ไม่สามารถกดคะแนนลงหรือยืนยันการแยกคลื่นสมองบริสุทธิ์ออกจากกล้ามเนื้อได้เด็ดขาด
   - ชี้ให้เห็นว่าโมเดลอาจไม่ได้เรียนรู้จาก Semantics ของคลื่นสมองแท้จริง แต่จับสัญญาณรบกวนร่วมและความต่อเนื่องของบล็อกการทดลอง (Session/Day Bias และ Cue)
3. **Overt & Mimed:**
   - การถ่ายทอดความรู้ข้ามโหมดภายในคนเดิมมีลักษณะเป็นทิศทางเดียว (Asymmetric): การฝึกจาก **`Mimed → Overt`** **ทำงานได้ดี (`~73.5%`)** คาดว่าเพราะบังคับให้โมเดลจับ Core features ที่ไม่มีเสียงรบกวน ในขณะที่ **`Overt → Mimed`** **ตกฮวบ (`~56–58%`)** เนื่องจากโมเดลอาจไปพึ่งพาฟีเจอร์ทางลัดจากการสั่นของเสียงหรือ Auditory feedback *(เป็นเพียงการตั้งสมมุติฐานเพื่อใช้ในการอธิบายผลการทดลอง จำเป็นต้องทดสอบในส่วนนี้เพิ่ม)*

Recommendations for Future Dataset Design

หากเราต้องการพัฒนา Speech BCI ที่พิสูจน์ได้ว่าอ่านคำพูดจากสมองจริงๆ โดยไม่ถูกหลอกด้วย Confound ของการทดลอง สิ่งสำคัญที่ต้องเปลี่ยนในการออกแบบการเก็บข้อมูล (Experimental Paradigm) ควรเป็นดังนี้:

1. **สุ่มสลับคำระหว่าง Trial (Interleaved / Event-Related Design):** เลิกเก็บข้อมูลแบบ Block ที่ให้พูดคำเดิมซ้ำๆ รวดเดียว 200 ครั้ง เพื่อตัดปัญหา Temporal Drift, ความเหนื่อยล้าเฉพาะช่วงเวลา และการที่โมเดลแอบจำสถานะของบล็อกแทนที่จะจำคำพูด
2. **กระจายทุกคำให้บันทึกครบทุกวัน (Multi-Day Balancing):** ให้ผู้เข้าร่วมพูดทุกคำในทุกวันของการทดลอง เพื่อกำจัดปัญหา **Day Bias** ไม่ให้โมเดลจำสภาพแวดล้อมของวันหรือความต้านทานอิเล็กโทรด (Electrode Impedance) ของวันนั้นๆ แทนคำพูด



Acknowledgments

ความสำเร็จและการเรียนรู้ตลอดโครงงานวิจัยนี้จะเกิดขึ้นไม่ได้ หากขาดจากการสนับสนุนจากผู้มีส่วนเกี่ยวข้องทุกท่าน:

- **โครงการ Brain Code Camp (BCC) 2026** ที่เปิดพื้นที่ ส่งเสริมทรัพยากร และผลักดันให้เกิดการทดลองวิจัยโครงงานนี้ขึ้น

- **ดร.อภิชญ์ เหมะคม และทีมวิจัย** จากศูนย์เทคโนโลยีอิเล็กทรอนิกส์และคอมพิวเตอร์แห่งชาติ (**NECTEC**), สำนักงานพัฒนาวิทยาศาสตร์และเทคโนโลยีแห่งชาติ (**สวทช.**) ผู้เอื้อเฟื้อชุดข้อมูล *Thai Overt-Mimed Speech EEG Dataset* ตลอดจนการให้ข้อมูลเชิงลึกและคำแนะนำเกี่ยวกับกระบวนการบันทึกข้อมูลผ่าน Personal communication
- **ดร.อิทธิ ฉัตรนันทเวช (อาจารย์ขนุน)** ผู้ดูแลหลักของโครงการ สำหรับคำแนะนำและการขับเคลื่อนโครงการ, **ดร.ปชญา สายลมุล (อาจารย์ปอ)** ที่ให้ความช่วยเหลืออย่างดียิ่งในการประสานงานเพื่อขอรายละเอียดและไขข้อสงสัยเกี่ยวกับ Dataset รวมถึงคณาจารย์ทุกท่านในโครงการ
- **พี่ออม — ชญานนท์ อรรถปักษ์, พี่โบนัส — ประภาสิริ เศวตสุทธิพันธ์** ผู้ช่วยสอน (TA) ประจำกลุ่ม รวมถึงทีมงาน TA ทุกท่านที่คอยให้คำปรึกษา แลกเปลี่ยนมุมมอง และสนับสนุนแนวทางการแก้ปัญหาตลอดช่วงการพัฒนาโปรเจกต์

(*รายชื่อ staff ทั้งหมด*)